

微分の概要について素人にも分かるように説明せよ

結論からいうと、以下のようにある関数 $f(x)$ 上の点を通る接線の傾きを得る操作を「微分」と言います。

例えば関数 $y = x^2$ 上の $x = 1$ の点Aとそこから x との距離が h 離れた $1 + h$ との2点間を通る直線の傾きを求めていきます。

$$\begin{aligned}\text{直線の傾き} &= \frac{(1+h)^2 - 1^2}{(1+h) - 1} \\ &= \frac{(1+2h+h^2) - 1}{h} \\ &= \frac{2h+h^2}{h} \\ &= 2+h\end{aligned}$$

となります。 x の2点間の距離 h を限りなく0に近づけていくと2点間を結ぶ直線の傾きは、 $x+h$ の h を0にしたときの値、つまり2になります。これは $y = x^2$ の1点A(1,1)を通る直線すなわち接線の傾きを求めたことになります。今度は $x=1$ 以外の全ての点における傾きを求めてみます。 $x=1$ の点Aでの接線の傾きを求めた方法と同様に、ある点 x から h だけ離れた点 $x+h$ との2点間を通る直線の傾きは

$$\begin{aligned}\text{変化の割合} &= \frac{y\text{の増加量}}{x\text{の増加量}} \\ &= \frac{(x+h)^2 - x^2}{(x+h) - x} \\ &= \frac{(x^2 + 2hx + h^2) - x^2}{(x+h) - x} \\ &= \frac{2hx + h^2}{h} \\ &= 2x + h\end{aligned}$$

2点間の x 座標の距離 h を限りなく0にすると、この式は $2x$ となります。したがって、関数 $y = x^2$ の各 x に対して、その点における傾きは $2x$ となります。

さらに一般化すると、 $y = f(x)$ において上記のように各 x の接線の傾きを求める式は以下のように表します。

$$f'(x) = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

この $f'(x)$ を導関数といい、さらにこの導関数を求めることを微分すると言います。

偏微分の概要について素人にも分かるように説明せよ

2つの変数 x, y で表された関数を $f(x, y)$ と書きます。このような関数を2変数関数と言います。 $f(x, y)$ は以下のように定義されているとします。

$$f(x, y) = x^2 + y^2 - xy$$

上記関数は x, y が同時に動きますが、どちらか一つの変数「だけ」に「偏って」見るとどうなるかを考えるのが偏微分の考え方です。例えば、 x の動きだけに偏って見ると y は動かず定数と同様にみなすことができます。すると、

$$f(x, y) = x^2 + y^2 - xy$$

を x で微分すると、 y は定数として扱って

$$2x + 0 - y = 2x - y$$

となります。これがxで「偏微分」するということになり、

$$\frac{\partial f(x, y)}{\partial x}$$

のように表します。同様に

$$f(x, y) = x^2 + y^2 - xy$$

をyで「偏微分」するとは、xを定数のように扱って以下のように表します。

$$\begin{aligned}\frac{\partial f(x, y)}{\partial y} &= 0 + 2y - x \\ &= 2y - x\end{aligned}$$

参照 https://detail.chiebukuro.yahoo.co.jp/qa/question_detail/q1125129201
(https://detail.chiebukuro.yahoo.co.jp/qa/question_detail/q1125129201)

微分/偏微分の機械学習、深層学習における使用について

機械学習、深層学習において、与えられたデータから今後未来に起こることを予測したい場合を考えます。与えられたデータをプロットしたグラフで、各点を通る関数がわかれば今後ある時点での予測ができるようになります。しかし関数が全ての点を通るわけではありません。そのときに関数を

$$f_{\theta}(x) = \theta_0 + \theta_1 x$$

とすると、データの値をyとすると誤差は $y - f_{\theta}(x)$ で表されますが、誤差には正負があるため誤差を2乗して正の値にすると、 $(y - f_{\theta}(x))^2$ とします。これはある一点のみに限定されているため、全部の値を足すと

$$E_{\theta} = \sum_{i=0}^n (y_n - f_{\theta}(x_n))^2$$

ここで便宜上この値に1/2をかけた値を二乗誤差といいます。

$$E_{\theta} = \frac{1}{2} \sum_{i=0}^n (y_n - f_{\theta}(x_n))^2 - (1)$$

この式の値を小さくして行くアプローチを最小2乗法といいます。 E_{θ} のことを目的関数ともいいます。この E_{θ} の値を小さくして行くときに微分を用います。たとえば二次関数 $g(x) = (x - 1)^2$ の最小値は $x = 1$ のときの $g(x) = 0$ になります。そのとき、 $x = 1$ の周辺で $g(x)$ の導関数の符号が変化しています。 $x < 1$ のときはマイナス、 $x > 1$ のときはプラスです。そのことを利用し導関数の符号によって与えられたxの値をずらして $x=1$ に近づけていけば値が最小値に近づいていきます。これは最急降下法、または勾配降下法ともよばれています。xの更新式は以下のように表されます。

$$x := x - \eta \frac{d}{dx} g(x) - (2)$$

と式で表します。「 $:=$ 」とは左辺を右辺で定義するという意味です。 η は学習率と呼ばれる正の定数です。また(1)の目的関数をみると、 E_{θ} は $g(x)$ と同じように下に凸になった二次曲線であるから、(2)の $g(x)$ のように当てはめることができるが、 $f_{\theta}(x)$ は θ_0 と θ_1 の2つのパラメータをもっているため、この E_{θ} は2つの変数を持つ二変数関数です。ですからこの場合の微分は偏微分をつかわなければなりません。ちなみに更新式は以下のようになります。

$$\theta_0 := \theta_0 - \eta \frac{d}{d\theta_0} (E)$$

$$\theta_1 := \theta_1 - \eta \frac{d}{d\theta_1} g(E)$$

合成関数の微分

例題 1

$$y = g(u) = u^4$$
$$u = f(x) = (x^2 + 3x + 1)$$

と定義すると $y = g(f(x))$ であるから

$$\begin{aligned}\frac{dy}{dx} &= \frac{dy}{du} \frac{du}{dx} \\ &= g'(f(x))f'(x) \\ &= 4(x^2 + 3x + 1)(2x + 3)\end{aligned}$$

例題 2

例題 1 と同様に

$$y = h(t) = \log t$$
$$t = g(u) = \sin(u)$$
$$u = f(x) = x^3 - 2$$

と定義すると $y = h(g(f(x)))$ であるから

$$\begin{aligned}\frac{dy}{dx} &= \frac{dy}{dt} \frac{dt}{du} \frac{du}{dx} \\ &= h'(t)g'(u)f'(x) \\ &= \frac{1}{t} \times \cos(u) \times 3x^2 \\ &= \frac{1}{\sin(u)} \times \cos(x^3 - 2) \times 3x^2 \\ &= \frac{3x^2 \cos(x^3 - 2)}{\sin(x^3 - 2)} \\ &= \frac{3x^2}{\tan(x^3 - 2)}\end{aligned}$$

合成関数の偏微分

$$h(x, y) = (x^2 + y^2)$$

$$g(x, y) = \sin xy$$

とすると $f = hg$ となり、両辺を x で偏微分すると

$$\begin{aligned}\frac{\partial f}{\partial x} &= \frac{\partial h}{\partial x} g + \frac{\partial g}{\partial x} f = 2x \sin xy + (x^2 + y^2) y \cos xy \\ &= x^2 y \cos xy + 2x \sin xy + y^3 \cos xy\end{aligned}$$